

# DATACON 2020 僵尸网络方向答辩



答辩队伍





- 难点与挑战
- **关键技术研究**
- 系统实现
- 总结与展望





# 难点与挑战

### 1. 现有工作的不足:

- 传统方法对于同源跨架构二进制代码分析精度低:
  - 例如 CG, CFG, ACFG 等控制流相关特性
- 依赖深度网络的方法对样本要求高:
  - 需要大量有标签的样本
  - 需要样本具有代表性与普遍性

少量样本下的较高 精度的特征工程?



# 难点与挑战

### 2. 数据集的特征:

- Rodata 段被抹去,符号表被 strip
  - 特征字符串和符号信息等直接信息缺失
- 编译器之间的差异
  - Function prologue和function epilogue存在差异
  - 内联函数的处理不同
- 一些源码中仅存在字符串长度的差异
  - 编译得到的binary控制流相似度高

有限信息和噪声下的有效特征选择?

- 研究背景与意义
- **关键技术研究**
- 系统实现
- 总结与展望





# 关键技术——用户定义函数识别

静态链接中

噪声遮盖用户源代码特征

大量libc函数



其他

start

用户定义函数

fcntl

其他



借助函数签名进行libc函数识别,剔除libc函数



# 关键技术

#### 書

大



### 其他



```
; Attributes: info from lumina
; int __cdecl fcntl(int fd, int cmd, struct flock *lock, char)
fcntl proc near
var C= dword ptr -0Ch
fd= dword ptr 4
cmd= dword ptr 8
lock= dword ptr 0Ch
arg_C= byte ptr 10h
        edi
                        ; Alternative name is '__GI__libc_fcntl
push
        ebx
push
sub
        esp, 14h
        ecx, [esp+1Ch+cmd]; cmd
mov
        eax, [esp+1Ch+arg C]
lea
        [esp+1Ch+var_C], eax
mov
        edi, [esp+1Ch+fd]
mov
        edx, [esp+1Ch+lock]; lock
mov
lea
        eax, [ecx-0Ch]
        eax, 2
cmp
        short loc_804F603
ja
```


```
<u></u>
loc 804F603:
push
        ebx
                        ; fd
mov
        ebx, edi
        eax, 37h; '7'
mov
int
        80h
                        ; LINUX - sys fcntl
pop
        ebx
        eax, 0FFFFF000h
cmp
        ebx, eax
mov
        short loc_804F623
ibe
```

```
<u></u>
fcntl:
var 10= -0x10
var 8= -8
var s0= 0
var_s4= 4
arg_8= 0x10
arg C= 0x14
li
        $gp, (off_4442F0+0x7FF0 - .)
addu
        $gp, $t9
addiu
        $sp, -0x28
        $ra, 0x20+var_s4($sp)
        $s0, 0x20+var_s0($sp)
        $gp, 0x20+var_10($sp)
addiu
        $v1, $a1, -0x21
addiu
        $v0, $sp, 0x20+arg C
       $v1, 3
sltiu
la
        $t9, sub_402430
        $v0, 0x20+var_8($sp)
        $a3, 0x20+arg_C($sp)
SW
        $v1, loc 4023F0
begz
        $a2, 0x20+arg_8($sp)
```

```
loc_4023F0:
li $v0, 0xFD7
syscall
la $t9, sub_4006B0
beqz $a3, loc_402418
move $s0, $v0
```



# 关键技术——用户定义函数Call Graph的建立






# 关键技术——rodata段的恢复



# 部分binary中仅字 符串长度存在差异



# 代码段无法体现完整特征



# 遍历sections,找到被抹掉的rodata段的范围

₿ LOAD	00400000	00400094
😛 .init	00400094	00400120
😛 .text	00400120	00403EB0
fini .fini	00403EB0	00403F0C
.ctors	00444000	00444008
.dtors	00444008	00444010
♣ LOAD	00444010	00444020
😝 .data	00444020	004442F0
😛 .got	004442F0	004444E0
🛟 .sbss	004444E0	004444E8
♣ LOAD	004444E8	004444F0
.bss	004444F0	00446638


♣ LOAD	00400000	00400094
.init	00400094	00400120
.text	00400120	00403EB0
😛 .fini	00403EB0	00403F0C
# roooodata	00403F0C	00444000
.ctors	00444000	00444008
.dtors	00444008	00444010
⊕ LOAD	00444010	00444020
.data	00444020	004442F0
.got	004442F0	004444E0
.sbss	004444E0	004444E8
♣ LOAD	004444E8	004444F0
🔒 .bss	004444F0	00446638



## 关键技术——rodata段的恢复




部分binary中仅字 符串长度存在差异



### 代码段无法体现完整特征



# 借助IDA的分析结果,获取rodata段中常量的数量、长度和使用位置





# 关键技术——binary跨架构特征构建



# 由于不同架构的编译器处 理不同(函数内联等)



### CFG存在差异



# 我们选取用户定义全局变量的访问作为核心特征


```
['unk_403F10', 'unk_403F18', 'dword_403F48', 'dword_403F48', 'dword_403F4C', 'byte_403F50', 'dword_403F54', 'dword_403F54', 'dword_403F58', 'unk_403F5C']
['dword_403FC0', 'dword_403FC0']
['unk_403FE0', 'unk_403FE8', 'unk_403FEC']
0x401e34
['unk_403FF0']
0x400120
['unk_403FFC', 'unk_440000', 'unk_440000']
['unk 403FFC', 'unk 440000', 'unk 440000']
0x4007e0
['unk_440000']
0x401ebc
['unk_440000']
0x403630
['unk 440000', 'unk 440000', 'unk 440000', 'unk 440000']
0x403e40
['unk 440000']
Function 0x0 cannot be identified!
{4210448: 8, 4210466: 48, 4210504: 4, 4210508: 4, 4210512: 4, 4210516: 4, 4210520: 4, 4210520: 4, 421064: 32, 4210656: 8, 4210664: 4, 4210668: 4, 4210672: 12, 4210684: 245764, 4456448: 16384}
```

- 研究背景与意义
- **全** 关键技术研究
- 系统实现
- 总结与展望






## 跨框架同源二进制识别流程








- 研究背景与意义
- **关键技术研究**
- 系统实现
- 总结与展望






# 工作总结与展望



- 本项目中我们使用user define functions识别、建立Call Graph、全局变量统计还原的方法对同源跨架构的binary进行了相似性分析,以达到细粒度的同源配对分析。
- 由于时间原因,我们在研究过程中还有许多ideas没能实践...



### Ideas



- 同架构下两个bianry代码相似性聚类的简单方法:在fileA中多次选取数条地址无关指令, 在fileB中寻找是否出现过该地址无关指令,以此计算两个binary的代码相似度。
- 对单一函数进行动态检查(黑盒),如果能保证该函数及其子调用不会有外部输入(全局变量、input、syscall),那么它的运行结果应该由其输入参数决定,我们可以写一个wrapper,构造好传入参数,以不同的输入多次调用该函数,使该函数成功执行,若两个binary中的该函数返回值相同,则可以认为这两个函数相同

# 谢谢!

